Relatório — Ouvidoria Inteligente

Decisões, Dificuldades e Aprendizados do Projeto

Disciplina: Tendências em Ciência da Computação
Alunas: Anna Maria, Maria Eduarda e Milena Azevêdo

1.INTRODUÇÃO

O projeto desenvolveu um protótipo de triagem semântica para as manifestações recebidas pela Ouvidoria Geral do município, hoje limitada a uma busca por palavras-chave que não detecta duplicatas, não agrupa temas relacionados descritos com vocabulário diferente e perde contexto em manifestações longas. O trabalho foi organizado em quatro entregas — comparação de representações vetoriais, detecção de duplicatas semânticas, chunking de textos longos e uma aplicação Streamlit integradora — e este relatório sintetiza as principais decisões técnicas tomadas ao longo do desenvolvimento, as dificuldades encontradas e os aprendizados consolidados pela equipe.

2. DECISÕES TÉCNICAS

2.1Entrega 1: Representação e modelagem

Substituição do modelo sugerido: o modelo BAAI/bge-small-pt-v1.5 indicado no enunciado não existe publicamente em português no Hugging Face; optou-se por usar dois modelos multilíngues do sentence-transformers (paraphrase-multilingual-MiniLM-L12-v2 e distiluse-base-multilingual-cased-v2) para manter a comparação entre representações densas.

Tratamento de stopwords: as palavras "sem" e "não" foram deliberadamente mantidas fora da lista de stopwords em português, por carregarem sentido central em reclamações (ex.: "posto de saúde sem médico").

Escolha do modelo principal: o MiniLM-L12 foi adotado como modelo de referência para as entregas seguintes por apresentar a maior margem de separação entre o par relevante e o par de controle indicados pelo professor.

Uso de percentil em vez de cosseno bruto: como a escala de similaridade difere muito entre representações esparsas e densas, optou-se por interpretar cada par pelo seu percentil na distribuição da própria representação, em vez de comparar valores absolutos de cosseno entre métodos.

2.2 Entrega 2: Detecção de duplicatas

Parametrização flexível: a função detectar_duplicatas foi projetada para aceitar tanto um limiar fixo de cosseno quanto um percentil da distribuição do corpus (ex.: "p99"), permitindo comparar cortes absolutos e relativos sem duplicar código.

Recalibração do limiar: o limiar sugerido no enunciado (0,85) foi substituído por 0,83, obtido por varredura de precisão/revocação/F1 contra um gabarito de três duplicatas reais do dataset, com critério de desempate para o limiar mais conservador (mais alto) dentro do platô de F1 máximo.

2.3 Entrega 3: Chunking de manifestações longas

Ferramenta e critério de seleção: usou-se o RecursiveCharacterTextSplitter (LangChain) e selecionaram-se as 5 manifestações com mais de 500 caracteres, aproveitando um salto natural no tamanho do texto para definir o corte.

Configuração adotada como padrão: entre as duas configurações testadas (200/20 e 400/100 caracteres, overlap/tamanho), a configuração longa (400/100) foi adotada como padrão no app por preservar melhor orações causais completas, mantendo os parâmetros ajustáveis pelo usuário.

2.4 Entrega 4: Aplicação Streamlit

Arquitetura em abas: o app_ouvidoria.py integra as três entregas anteriores em quatro abas (Busca Semântica, Base Completa, Espaço Vetorial e Chunking), com destaque visual por cor conforme o score de similaridade.

Uso de cache: modelo e dados foram armazenados com st.cache_resource e st.cache_data, respectivamente, para evitar recarregar o modelo ou recalcular vetores a cada interação do usuário.

3. DIFICULDADES ENCONTRADAS

Modelo indisponível: o modelo de embeddings em português sugerido pelo enunciado não estava disponível publicamente, exigindo pesquisa e substituição por uma alternativa multilíngue equivalente.

Limiar sugerido inadequado: aplicado diretamente, o limiar de 0,85 do enunciado não detectou nenhuma duplicata no corpus — nem a duplicata mais evidente (M006×M028, cosseno 0,8351) o ultrapassa — o que exigiu recalibração a partir da própria distribuição do corpus.

Escalas incomparáveis entre representações: a similaridade média entre pares aleatórios já é de 0,17 a 0,23 nos embeddings, contra 0,02 a 0,04 em BoW/TF-IDF, o que impede comparar valores brutos de cosseno diretamente entre métodos.

Falso negativo persistente: mesmo após a recalibração, a duplicata mais sutil do dataset (M003×M017, sem nenhuma palavra em comum) permaneceu não detectada, ficando atrás de dezenas de pares não duplicados na ordenação por similaridade.

Falsos positivos por confusão temática: em boa parte dos falsos positivos, os embeddings aproximaram manifestações da mesma categoria oficial que descreviam incidentes diferentes, evidenciando que o modelo por vezes capta semelhança de tema com mais força do que semelhança de instância.

Corte de sentido no chunking curto: a configuração curta (200/20) chegou a dividir ao meio orações causais que descreviam o núcleo da denúncia, um problema que a configuração longa (400/100) resolveu.

Pendências dependentes de execução final: as leituras dos gráficos de projeção 2D (PCA/t-SNE) das Entregas 3 e 4, assim como parte da divisão de tarefas da equipe, dependiam da execução final dos notebooks com os modelos reais e precisaram ser fechadas apenas na reta final do projeto.

4. APRENDIZADOS

Densas vs. esparsas: representações densas (embeddings) superam representações esparsas (BoW/TF-IDF) na tarefa de similaridade semântica, mas ao custo de uma linha de base de similaridade mais alta e menos interpretável.

Calibração baseada em percentil: interpretar cada similaridade pelo percentil da própria distribuição do corpus é mais informativo — e mais transferível entre bases diferentes — do que adotar um valor absoluto de cosseno importado de outro contexto.

Limite do threshold único: um único limiar de cosseno é uma aproximação imperfeita para semântica de paráfrase: qualquer ponto de corte envolve uma troca entre precisão e revocação, e casos sutis de duplicata podem escapar mesmo de um limiar bem calibrado.

Overlap proporcional importa: aumentar o overlap proporcionalmente ao tamanho do chunk (25% vs. 10%) reduz de forma perceptível o risco de cortar ao meio a oração que carrega o núcleo do problema relatado.

Potencial de abordagens híbridas: combinar sinais lexicais (termos em comum, entidades nomeadas como rua/bairro) aos embeddings tende a reduzir falsos positivos gerados por semelhança apenas temática, sem abrir mão da cobertura semântica dos modelos densos.

Engenharia de aplicação: em uma interface interativa que recalcula vetores e similaridades, o uso disciplinado de cache (st.cache_resource/st.cache_data) é tão relevante para a experiência do usuário quanto a qualidade do modelo escolhido.

5. CONSIDERAÇÕES FINAIS

As decisões tomadas ao longo das quatro entregas convergem para uma conclusão comum: modelos de embeddings resolvem boa parte das limitações da busca por palavras-chave da Ouvidoria, mas exigem calibração cuidadosa — de limiares, de configurações de chunking e de expectativas sobre o que a similaridade de cosseno realmente mede. As dificuldades enfrentadas, sobretudo a inadequação de parâmetros sugeridos de forma genérica (modelo indisponível, limiar de duplicata fora de escala), reforçam a importância de validar empiricamente cada escolha contra o corpus real antes de adotá-la como padrão, prática que orientou o desenvolvimento do protótipo do início ao fim.